Informe — Trabajo Práctico N.º 2: embeddings y búsqueda semántica

Procesamiento del Lenguaje Natural · Grupo: Hinrichsen, Erica……

Construimos buscadores de libros sobre las 200 sinopsis de ciencia ficción del TP1 y los evaluamos con 10 consultas propias: 8 temáticas y 2 redactadas a propósito sin ninguna palabra en común con los libros que buscan. Para cada consulta definimos de antemano qué libros son relevantes. La medida principal es la **precisión en los 5 primeros resultados (P@5)**: de los cinco libros que devuelve el buscador, qué fracción es relevante. La Tabla 1 resume los resultados.

Método	P@5 promedio (10 consultas)	Consultas temáticas (8)	Consultas sin palabras en común (2)
Elegir al azar (piso)	0,03	—	—
TF-IDF (línea de base)	0,18	0,23	0,00
Word2Vec entrenado con nuestro corpus	0,14	0,18	0,00
Word2Vec pre-entrenado (SBW)	0,14	0,18	0,00
SBERT distiluse (modelo de oración)	0,24	0,28	0,10
E5 small (modelo de oración)	**0,30**	**0,33**	**0,20**
Búsqueda por palabras de Postgres	0,30	0,38	0,00
Híbrida: E5 + búsqueda por palabras	**0,34**	**0,40**	**0,10**

Tabla 1. Precisión en los 5 primeros resultados. Elegir 5 libros al azar acierta, en promedio, 0,03.

1. ¿Qué modelo elegiríamos para producción y por qué?

Elegiríamos la **búsqueda híbrida**, que combina el modelo de oración E5 con la búsqueda por palabras: tiene la mejor precisión (0,34) y en ninguna consulta quedó por debajo de sus dos componentes a la vez. Pero la métrica sola no alcanza para decidir: frente a E5 solo o a la búsqueda por palabras sola, la mejora es de apenas 2 aciertos más en 50 resultados (gana en 2 consultas y pierde en 1), una diferencia que con 10 consultas no se distingue del azar. Por eso pesan los otros criterios:

- **Costo.** No hay pago por consulta. E5 es un modelo chico (vectores de 384 números, contra 512 de SBERT) y en nuestro trabajo corrió en el procesador común de Colab, sin placa gráfica. La búsqueda por palabras no necesita ningún modelo.
- **Privacidad.** E5 se ejecuta en el mismo entorno que el buscador (en nuestro caso, Colab): las consultas de los usuarios no se envían a la API de otra empresa para ser procesadas.
- **Reproducibilidad.** E5 es un modelo ya entrenado: si se fija su versión, el mismo texto da siempre el mismo resultado. La regla para combinar las dos listas se fijó antes de evaluar y no tiene azar. Esto contrasta con el Word2Vec que entrenamos: con otra semilla, sus palabras vecinas cambiaban mucho (solo entre 43 % y 82 % coincidían).
- **Dependencia de terceros.** E5 se descarga de Hugging Face; si dejara de estar disponible, la búsqueda por palabras sigue funcionando sola con una pérdida acotada (P@5 = 0,30).

Descartamos SBERT distiluse porque solo lee los primeros 128 fragmentos de texto: 168 de las 200 sinopsis quedaron cortadas, y en la mediana el modelo no ve el 42 % de cada una. Descartamos los Word2Vec porque no superan a TF-IDF.

2. ¿Cuánto mejor es que la línea de base TF-IDF? ¿Dónde gana y dónde no?

E5 mejora a TF-IDF de 0,18 a 0,30 de P@5: gana en 6 consultas, empata en 3 y pierde en 1. La híbrida llega a 0,34 y gana en 6 sin perder en ninguna. Hay dos matices importantes. Primero, **la línea de base importa**: una versión de TF-IDF que descartaba las palabras presentes en un solo libro (como “piratas” o “totalitarios”) daba 0,14, y contra ella la mejora de E5 parecía mayor (+0,16 en vez de +0,12). Segundo, **una búsqueda por palabras mejor hecha alcanza a E5**: la de Postgres, que reconoce variantes de una misma palabra (“viajes” y “viaje”), obtiene la misma P@5 que E5 (0,30).

- **Donde ganan los modelos de oración:** en las consultas sin palabras en común con los libros buscados. Ahí los métodos por palabras dan 0 por construcción: la consulta no coincide con ningún texto y el orden de los resultados es arbitrario. E5 acierta 0,20 y SBERT 0,10. También ganan en consultas más abstractas: en "la vida de los sobrevivientes después de una catástrofe", E5 obtuvo 0,4 y la búsqueda por palabras 0.
- **Donde gana o empata la búsqueda por palabras:** cuando la consulta usa el mismo vocabulario que las sinopsis. En "la humanidad viaja en naves hacia otro planeta" la búsqueda por palabras obtuvo 0,6 y E5 0,2; en "expediciones científicas a lugares remotos" empataron en 0,4. En el promedio de las consultas temáticas, la búsqueda por palabras (0,38) supera a E5 (0,33).
- **Por qué conviene combinarlas:** aciertan libros distintos. De 22 libros relevantes que encuentra alguna de las dos, 7 los encuentra solo E5, 7 solo la búsqueda por palabras y 8 ambas. La híbrida recupera 17.

En valores absolutos, el mejor método acierta 1,7 de cada 5 libros: unas diez veces más que el azar, pero lejos de un buscador perfecto. Los Word2Vec no superan a TF-IDF: nuestro corpus (unas 15.000 palabras útiles) es demasiado chico para entrenar uno propio, y el promedio de vectores pre-entrenados hace que todas las sinopsis se parezcan entre sí.

3. ¿Qué mide y qué no mide la métrica que usamos?

P@5 mide qué fracción de los cinco primeros resultados cumple un criterio de relevancia escrito antes de ver los resultados, y permite comparar todos los métodos en la misma escala. **No mide:**

- el orden dentro de los cinco primeros: acertar en el primer puesto vale lo mismo que en el quinto;
- los relevantes que quedan afuera: en la consulta sobre primer contacto alienígena, el primer libro relevante de E5 está en el puesto 14, y P@5 lo cuenta igual que si estuviera en el 150;
- grados de relevancia: es sí o no. Si contamos también los libros "dudosos" (cercanos al tema, pero no centrales), E5 sube de 0,30 a 0,44 y el Word2Vec pre-entrenado se duplica (de 0,14 a 0,28);
- lo que nuestra lista de relevantes no incluye: entre 8 y 18 libros por consulta aparecieron entre los primeros cinco de algún método sin haber sido evaluados. P@5 subestima a los métodos que encuentran libros que no anticipamos; por ejemplo, SBERT trajo *Truel1f3* para la consulta sobre autómatas, que parece cumplir el criterio y no estaba en la lista.

Además, con 10 consultas cada acierto mueve el promedio 0,02, así que solo se pueden detectar diferencias grandes. Cuando una consulta tiene menos de cinco relevantes, P@5 tiene un techo (con 4 relevantes, el máximo es 0,8). Y las series que comparten texto la inflan: acertar un libro de la serie de Bill suele traer a los demás.

4. Un caso donde la búsqueda falló, y nuestra hipótesis

Consulta: "primer encuentro y comunicación con una inteligencia alienígena". Ningún método acertó ni un libro en los cinco primeros. E5 devolvió *Una mirada a Alice B. Sheldon* y *El gran espectáculo* (ambos dudosos), *La utopía de Turing*, *Un puente sobre el tiempo* y *Una memoria llamada Imperio*. Los cinco relevantes quedaron en los puestos 14, 21, 51, 62 y 141. Tenemos tres hipótesis:

- **Parte de la falla es de nuestro criterio.** Las dos primeras sinopsis hablan literalmente del "primer contacto con una raza alienígena" y de "los primeros contactos alienígenas", pero las marcamos como dudosas por ser antologías. Contándolas, P@5 sería 0,4.
- **El modelo no deduce lo que la sinopsis no dice.** *Ruido fractal* (puesto 141) cuenta que un equipo viaja a un planeta para "descubrir quiénes han construido el agujero", sin usar nunca "alienígena" ni "contacto". Un lector entiende que es un primer contacto; el modelo no. En *El problema de los Tres Cuerpos* (puesto 51), el tema aparece recién en la última oración, después de una frase publicitaria idéntica en los tres libros de la saga.

- **Una palabra suelta arrastra el resultado.** “Inteligencia” atrae a *La utopía de Turing*, cuya sinopsis habla de “inteligencia artificial”. *Un puente sobre el tiempo*, una comedia romántica con viajes en el tiempo, no tiene relación con el tema; podría ser un libro que el modelo ubica cerca de muchas consultas, algo que no llegamos a verificar.

La combinación tiene además una falla propia: favorece a los libros que aparecen en las dos listas. En la consulta sobre autómatas, *Protocolo rebelde* era el primero de E5 y relevante, pero bajó al tercer puesto, detrás de dos libros que aparecían en posiciones intermedias de ambas listas. En consultas sin palabras en común, la lista por palabras solo aporta coincidencias accidentales; es la explicación más probable de que en la consulta sobre comedias la híbrida perdiera el acierto que tenía E5.

Uso de asistentes de IA

Usamos Claude (Anthropic) como asistente durante el trabajo: para escribir borradores del código de cada parte, resolver errores de instalación y de conexión y ayudarnos a interpretar las salidas del notebbok. El asistente también propuso la primera versión de las consultas de evaluación y de sus libros relevantes. Esa primera versión tuvo al menos una omisión probable: no incluía *Truel1f3* entre los relevantes de la consulta sobre autómatas .

Todas las cifras de este informe provienen de la ejecución del notebook por parte del grupo y fueron contrastadas con esas salidas.